Proyecto Computacional

Profesor: Alexander Kozachinskiy, alexander.kozachinskyi@cenia.cl
Ayudante: Victoria Otarola, victoriaotarola@estudiante.uc.cl,

Objetivo

En este proyecto aplicarán la a una colección de textos para descubrir estructura latente en los datos. La meta es usar herramientas de álgebra lineal para representar documentos y términos en dimensión reducida, interpretar los resultados y discutir sus límites.

Indicaciones Generales

- **Grupos:** El proyecto se realiza en grupos de 2 o 3 estudiantes.
- **Corpus:** Cada grupo debe elegir un corpus propio. Los datos deben ser públicos y reproducibles.
- **Código:** El código debe quedar en un repositorio público de GitHub. El repositorio debe incluir instrucciones de ejecución, enlace o instrucciones para descargar los datos, y los archivos necesarios para reproducir figuras y resultados.
- **Informe:** Se debe entregar por correo al profesor, con copia al correo de la ayudante, un informe final en formato .pdf. El informe debe ser breve, claro y bien estructurado. Debe incluir el link al repositorio con código.

  Puede escribirse en Overleaf o en otra herramienta, pero el resultado final debe ser un PDF.
- **Plazo:** 30 de Noviembre 2026.

Herramientas Esperadas

Python debiera ser el lenguaje principal del proyecto. Una combinación razonable de librerías es:

- `numpy` para álgebra lineal y manejo de arreglos;
- `pandas` para tablas y organización de datos;
- `matplotlib` o `seaborn` para visualizaciones;
- `scikit-learn` para construir término-documento con TF-IDF;
- `scipy` si necesitan trabajar con matrices dispersas.

- `nltk` o `spaCy` para tareas básicas de procesamiento de texto.

Pueden trabajar en Google Colab o en un notebook de Jupyter local. Lo importante es que el código sea fácil de ejecutar y reproducir.

Descripción del proyecto

El objetivo de este proyecto es realizar un análisis semántico latente, o LSA por su nombre en inglés *Latent Semantic Analysis*, usando SVD.

La idea central es construir una matriz "termino-documento" que represente una colección de documentos, aplicar SVD, conservar algunas componentes principales e interpretar la representación reducida como una aproximación de la estructura semántica del corpus.

Las columnas de la matriz representan documentos de su corpus. Las filas representan términos relevantes. La intersección de la fila t y la columna d tiene que describir la frecuencia del termino t dentro del documento d.

Paso 1 – elección y descripción del corpus. Elijan un corpus con al menos 50 documentos. Cada documento debe tener una cantidad razonable de texto y la fuente debe ser abierta.

Describan la fuente de los datos, indiquen cuántos documentos usarán y expliquen por qué el corpus es interesante. Incluyan una tabla o resumen con el número de documentos y la fuente.

Algunos ejemplos posibles son abstracts de artículos científicos, noticias, discursos políticos, letras de canciones, reviews de productos u otro corpus público que el grupo considere apropiado. Pueden buscar datos en Kaggle, Hugging Face Datasets u otras fuentes abiertas.

Paso 2 – hipótesis inicial. Antes de realizar el análisis, propongan una hipótesis sobre la estructura del corpus.

Por ejemplo, pueden anticipar temas posibles, grupos de documentos, palabras importantes o separaciones esperadas entre categorías. La salida esperada es un párrafo corto con una hipótesis inicial concreta.

Paso 3 – preprocesamiento del texto. Limpien el texto para construir un vocabulario útil.

Como mínimo, expliquen qué decisiones tomaron sobre tokenización, normalización, eliminación de stopwords y de términos poco informativos. Se recomienda usar TF-IDF en lugar de conteos crudos. También pueden incluir lematización y n-gramas si esto ayuda al corpus elegido.

Reporten el tamaño del vocabulario final y expliquen brevemente por qué el preprocesamiento elegido es razonable.

Paso 4 – construcción de la matriz textual. Construyan la matriz A que será analizada con SVD.

Si su vocabulario de términos es de tamaño m, y el corpus es de tamaño n, la matriz A tendría que ser de tamaño $m \times n$.

Si usan scikit-learn, recuerden que sus vectorizadores suelen entregar una matriz con documentos en las filas y términos en las columnas; pueden transponerla en ese caso.

Paso 5 – cálculo de la SVD. Calculen la descomposición SVD

$$A = U\Sigma V^T.$$

Aclaren que parámetros del método SVD usaron, y qué dimensiones tienen las matrices U, Σ, V.

Paso 6 – análisis de valores singulares Analicen cuánto de la estructura del problema se concentra en pocas componentes.

Grafiquen los valores singulares, observen su decaimiento y elijan un valor razonable de k para una representación reducida. Justifiquen brevemente la elección de k.

Paso 7 – representación de documentos y términos en baja dimensión. Usen pares de componentes de la SVD para construir representaciones 2D reducidas.

Para los términos, representados como filas de A, tienen que elegir un par de vectores singulares v_a, v_b por la derecha y proyectar las filas de A en el plano $Span(v_a, v_b)$, utilizando las coordenadas en la base v_a, v_b para una visualización 2D de términos. Asimismo, para la visualización 2D de documentos, tienen que elegir un par de vectores u_a, u_b por la izquierda y hacer una proyección correspondiente.

Expliquen brevemente la manera en que han calculado estas proyecciones en su código.

Incluyan una visualización 2D de documentos y una visualización 2D de palabras o términos relevantes, indicando qué par de componentes usaron y por qué. Interpreten agrupamientos, separaciones o asociaciones observadas.

Paso 8 – exploración semántica. Usen la representación reducida para explorar relaciones en el corpus. Para visualizar en dos dimensiones, pueden elegir cualquier par de componentes. En particular, es natural comenzar con las dos primeras componentes, porque corresponden a los dos valores singulares más grandes (y la mejor aproximación de rango 2). Sin embargo, puede ocurrir que otro par de componentes va a entregar más información semántica.

Incluyan 2 o 3 ejemplos concretos, como palabras cercanas, documentos cercanos, componentes con posible significado temático o grupos de documentos que parezcan relacionados. Expliquen por qué esos ejemplos son coherentes o sorprendentes.

Paso 9 – discusión, limitaciones y conclusiones. Comparen los resultados con la hipótesis inicial.

Indiquen si la hipótesis se cumple o no, expliquen resultados esperados e inesperados, y discutan límites del método y del corpus. Recuerden que LSA no reemplaza la lectura del corpus: sirve como herramienta exploratoria para descubrir patrones, formular hipótesis y construir visualizaciones de baja dimensión.

Checklist mínimo de entrega

La entrega debe incluir, al menos:

- corpus descrito y fuente citada;
- hipótesis inicial;
- matriz término-documento construida;
- SVD calculada;
- gráfico de valores singulares;
- visualización 2D de documentos;
- visualización 2D de palabras o términos;
- ejemplos de exploración semántica;
- discusión final;
- código reproducible en GitHub.

Entrega ideal

Una entrega bien lograda debería mostrar que el corpus está bien explicado, que la fuente está claramente indicada, que la hipótesis inicial se conecta con el análisis, que la matriz textual está bien construida, que la SVD se usa correctamente y no solo como una caja negra, que las visualizaciones ayudan a entender el problema, que la discusión final compara resultados con la hipótesis inicial y que el repositorio permite repetir el análisis sin ambigüedad.

La entrega ideal resulta en sumar $0,5$ a la nota final del curso, con la evaluación proporcional de los proyectos hechos parcialmente.